Robot nhận diện cảm xúc đa phương thức và hỗ trợ cá nhân hóa

Trần Thị Phương, Trần Thị Kim Thi, Phạm Quốc Thiện
Trường Đại học Công nghệ TP.HCM

Trần Thị Kim Thi
Viện kỹ thuật Hutech
Đại học Công nghệ Tp.HCM
Hồ Chí Minh, Việt Nam
kimthi.1450@gmaiil.com

Trần Thị Phương
Viện kỹ thuật Hutech
Đại học Công nghệ Tp.HCM
Hồ Chí Minh, Việt Nam
ttphuong10404@gmail.com

***Tóm tắt* - Bài báo này đề xuất một hệ thống robot nhận diện cảm xúc đa phương thức nhằm tương tác và phản hồi phù hợp với trạng thái cảm xúc của người dùng. Hệ thống khai thác đồng thời dữ liệu hình ảnh khuôn mặt và tín hiệu giọng nói để suy luận cảm xúc. Ở kênh âm thanh, các đặc trưng giọng nói được trích xuất và đưa vào mô hình kết hợp CNN–LSTM–SVM huấn luyện trên tập dữ liệu TESS. Ở kênh hình ảnh, mô hình MobileNetV2 được sử dụng để nhận diện cảm xúc khuôn mặt dựa trên tập dữ liệu FER2013. Kết quả dự đoán từ hai kênh được hợp nhất (decision-level fusion) để tạo ra nhãn cảm xúc cuối cùng. Hệ thống được đánh giá bằng các chỉ số định lượng (Accuracy, F1-score, …) và thử nghiệm người dùng trong kịch bản mô phỏng, qua đó cho thấy tiềm năng ứng dụng như một bạn đồng hành hỗ trợ cảm xúc.**

***Từ khóa* - nhận diện cảm xúc, học đa phương thức, tương tác người-robot, xử lý hình ảnh, xử lý giọng nói, cá nhân hóa.**

I. GIỚI THIỆU

Vấn đề Sức khỏe Toàn cầu: Sức khỏe tâm thần đã trở thành một trong những vấn đề y tế toàn cầu cấp bách nhất của thế kỷ 21. Tổ chức Y tế Thế giới (WHO) báo cáo rằng hơn 970 triệu cá nhân trên toàn thế giới đã bị ảnh hưởng bởi rối loạn tâm thần vào năm 2022, trong đó trầm cảm và lo âu là những rối loạn phổ biến nhất[1][2].

Khoảng cách Điều trị: Căng thẳng do bệnh tâm thần gia tăng bởi sự hạn chế về số lượng nhà cung cấp dịch vụ chăm sóc sức khỏe có trình độ. Việc sử dụng robot xã hội có thể giúp giảm bớt "khoảng cách điều trị" này. [3][4].Việc sử dụng robot xã hội có thể giúp giảm bớt những vấn đề đang tồn tại này.

Robot/trợ lý xã hội có tiềm năng hỗ trợ người dùng thông qua tương tác tự nhiên và phản hồi phù hợp với trạng thái cảm xúc. Tuy nhiên, nhận diện cảm xúc trong điều kiện thực tế vẫn khó do tín hiệu đầu vào dễ nhiễu và có thể không nhất quán giữa khuôn mặt và giọng nói. Nghiên cứu này đề xuất một hệ thống nhận diện cảm xúc đa phương thức gồm hai nhánh độc lập: (i) SER từ giọng nói và (ii) FER từ khuôn mặt, tập trung vào 4 trạng thái (*vui, buồn, tức giận, bình thường*). Kết quả từ hai nhánh được hợp nhất ở mức quyết định để tạo nhãn cuối cùng và phục vụ mô-đun phản hồi[5].

Tái đánh giá nhận thức giúp thay đổi cách diễn giải các tình huống áp lực để khôi phục khả năng phục hồi bền vững.[10] Việc tương tác lặp lại khuyến khích biểu đạt cảm xúc cao hơn, cho phép người tham gia đối mặt với những trải nghiệm tiêu cực mà họ thường lảng tránh[6]. Theo thuyết gắn bó của Bowlby, nhà trị liệu đóng vai trò là hình mẫu gắn bó và điểm tựa an toàn nhằm sửa chữa các mô hình cảm xúc bất ổn[7]. Mối quan hệ này thể hiện qua 5 đặc điểm: tìm kiếm sự gần gũi, nơi trú ẩn an toàn, nền tảng an ninh để khám phá, lo âu chia ly, và sự dẫn dắt mạnh mẽ, khôn ngoan hơn[8]. Về xúc giác, các can thiệp này hiệu quả trong việc điều hòa cortisol và tăng cân ở trẻ sơ sinh, cũng như giảm đau, trầm cảm và lo âu ở người lớn[9]. Đồng thời, phản hồi vật lý từ xúc giác giúp tăng cường sự tập trung bằng cách tách rời cá nhân khỏi các suy nghĩ gây xao nhãng[10].

Để giải quyết bài toán nhận diện cảm xúc qua hình ảnh. Việc đáp ứng yêu cầu triển khai nhận diện cảm xúc khuôn mặt trên Jetson Nano, mô hình cần vừa đảm bảo độ chính xác, vừa có kích thước nhỏ và chi phí tính toán thấp để suy luận thời gian

thực. Các nghiên cứu benchmark trên FER2013 cho thấy nhiều kiến trúc CNN truyền thống tuy đạt độ chính xác tương đối tốt nhưng có kích thước mô hình rất lớn, gây bất lợi khi triển khai trên phần cứng hạn chế: ví dụ VGG16 đạt 67.7% nhưng file trọng số lên đến 512 MB, và ResNet50 đạt 68.1% với 81.3 MB; trong khi đó các kiến trúc MobileNet (V1) đạt 67.1% với chỉ 12.3 MB, thể hiện ưu thế rõ rệt về dung lượng mô hình mà vẫn duy trì độ chính xác cạnh tranh trên FER2013 [11]. . Do đó, chúng tôi chọn MobileNet và ưu tiên MobileNetV2 vì Jiang *et al.* báo cáo MobileNetV2 đạt 66.68% cao hơn MobileNetV1 (61.54%) khi huấn luyện thuần trên FER2013[12].

Để tối ưu hóa bài toán nhận diện cảm xúc trên thiết bị nhúng, đề tài sử dụng phương pháp thực nghiệm so sánh giữa hai mô hình: 2D-CNN thuần (Mô hình cơ sở) và Hybrid CNN-LSTM (Mô hình đề xuất). Trong khi CNN chỉ xử lý phổ âm thanh dưới dạng ảnh tĩnh để trích xuất đặc trưng tần số, kiến trúc Hybrid tích hợp thêm lớp LSTM nhằm ghi nhớ chuỗi thời gian, giúp hệ thống nắm bắt được sự thay đổi ngữ điệu. Kết quả kiểm thử trên cùng tập dữ liệu cho thấy Hybrid CNN-LSTM vượt trội về độ chính xác và khả năng tổng quát hóa, chứng minh tính hiệu quả của việc kết hợp xử lý không gian và thời gian trong bài toán này.

Công nghệ nhận diện cảm xúc đa phương thức là một nhánh nghiên cứu quan trọng trong lĩnh vực Trí tuệ nhân tạo(AI). Thách thức lớn nhất là khả năng nhận thức và phân tích cảm xúc con người.[8] Tại một nghiên cứu kết hợp mô hình ML đa phương thức với nguyên tắc lòng trắc ẩn, họ có thể đánh giá và gộp các phương thức để đưa ra kết quả dựa vào hiệu suất phân loại tổng thể dựa trên độ chính xác của hai dữ liệu đầu vào là giọng nói và khuôn mặt.[1] Hoặc ở một dự án khác các tác giả lại lựa chọn việc tính trung bình cộng trọng số của các model và ưu tiên vào mức độ tin cậy. Nhưng phức tạp hơn là sự không nhất quán giữa khuôn mặt và lời nói thì đòi hỏi robot phải bắt chuyện và dẫn dắt để người dùng có thể đối diện với cảm xúc thật hoặc có thể điều chỉnh hành vi thích ứng cho việc nhận diện không nhất quán [9]. Từ đó, nghiên cứu này áp dụng hợp nhất ở mức quyết định và khi hai kênh không nhất quán thì kích hoạt cơ chế hỏi–gợi mở để làm rõ cảm xúc.

Đóng góp chính của bài báo gồm:

1. Xây dựng và huấn luyện thành công mô hình nhận diện cảm xúc qua giọng nói (Speech Emotion Recognition - SER) với khả năng phân loại 04 trạng thái: vui, buồn, tức giận và trung tính. Độ chính xác trên 95%.
2. Xây dựng và huấn luyện thành công mô hình nhận diện cảm xúc qua hình ảnh khuôn mặt (Facial Emotion Recognition - FER) với khả năng phân loại 04 trạng thái tương ứng. Độ chính xác trên 80%.
3. Hệ thống có khả năng nhận diện độc lập từ hai nguồn dữ liệu đầu vào khác nhau (âm thanh và hình ảnh). Đưa ra được nhãn cảm xúc cụ thể khớp với trạng thái thực tế của đối tượng.
4. Thiết lập đánh giá bằng các chỉ số định lượng (Accuracy, Macro-F1/F1-score) và thử nghiệm người dùng theo kịch bản mô phỏng.

[1] I. O. Adewumi, "Multimodal Emotion Recognition and Human Computer Interaction for AI-Driven Mental Health Support," *Journal of BioMed Research and Reports*, vol. 8, no. 5, pp. 1-8, 2025, doi: 10.59657/2837-4681.brs.25.205.

[2] R. Arakawa, M. Nakagawa, and H. Yakura, "UbiLearn: Supporting English-as-a-Foreign-Language Learners in Reflecting on Conversations Using a Smartwatch MHCI033," *Proceedings of the ACM on Human-Computer Interaction*, vol. 9, no. 5, pp. 1-29, 2025, doi: 10.1145/3743735.

[3] R. Chengoden *et al.*, "Metaverse for Healthcare: A Survey on Potential Applications, Challenges and Future Directions," *IEEE Access*, vol. 11, pp. 12765-12795, 2023, doi: 10.1109/access.2023.3241628.

[4] Y. Cohen, M. Faccio, and S. Rozenes, "Vocal Communication Between Cobots and Humans to Enhance Productivity and Safety: Review and Discussion," *Applied Sciences*, vol. 15, no. 2, 2025, doi: 10.3390/app15020726.

[5] E. Ezra Tsur and O. Elkana, "Intelligent Robotics in Pediatric Cooperative Neurorehabilitation: A Review," *Robotics*, vol. 13, no. 3, 2024, doi: 10.3390/robotics13030049.

[6] L. T.-L. Huang, T.-W. Hung, and Y.-T. Lin, "The dynamics of personal autonomy: a comprehensive framework for evaluating human-carebot interactions," *Asian Journal of Philosophy*, vol. 4, no. 2, 2025, doi: 10.1007/s44204-025-00334-3.

[7] H. W. Jung, J. Y. Park, T. Holoubek, W. J. Kim, and J. Park, "Socially Assistive Robots in Mental Healthcare: Principles and Conceptual Framework for User-Centered Design," *International Journal of Social Robotics*, vol. 17, no. 11, pp. 2827-2851, 2025, doi: 10.1007/s12369-025-01323-5.

[8] S. Kalateh, L. A. Estrada-Jimenez, S. Nikghadam-Hojjati, and J. Barata, "A Systematic Review on Multimodal Emotion Recognition: Building Blocks, Current State, Applications, and Challenges," *IEEE Access*, vol. 12, pp. 103976-104019, 2024, doi: 10.1109/access.2024.3430850.

[9] G. Laban, V. Morrison, A. Kappas, and S. C. E, "Coping with Emotional Distress via Self-Disclosure to Robots: An Intervention with Caregivers," *Int J Soc Robot*, vol. 17, no. 9, pp. 1837-1870, 2025, doi: 10.1007/s12369-024-01207-0.

[10] J. T. Licardo, M. Domjan, and T. Orehovački, "Intelligent Robotics—A Systematic Review of Emerging Technologies and Trends," *Electronics*, vol. 13, no. 3, 2024, doi: 10.3390/electronics13030542.

[11] Qian, C., Lobo Marques, J. A., de Alexandria, A. R., & Fong, S. J. (2025). Application of multiple deep learning architectures for emotion classification based on facial expressions. *Sensors*, *25*(5), 1478.

[12] Jiang, D., Zhang, S., Yu, C., & Tian, C. (2020, August). A Bi-directional Residual Network for Image Expression Recognition. In *International Conference on Simulation Tools and Techniques* (pp. 173-182). Cham: Springer International Publishing

[13] K. Matheus, E. Mamantov, M. Vázquez, and B. Scassellati, "Deep Breathing Phase Classification with a Social Robot for Mental Health," presented at the International Conference on Multimodal Interaction, 2023.

[14] K. Matheus, M. Vázquez, and B. Scassellati, "Ommie: The Design and Development of a Social Robot for Anxiety Reduction," *ACM Transactions on Human-Robot Interaction*, vol. 14, no. 2, pp. 1-34, 2025, doi: 10.1145/3706122.

[15] A. Nyamathi *et al.*, "Establishing the Foundations of Emotional Intelligence in Care Companion Robots to Mitigate